제조 생산데이터 기반 전력사용량 예측 및 최대피크 위험조건 분석

KAMP 자원 최적화 AI 데이터셋 — 과제 ⑤ 분석 보고서

2026년 10월

요약

- 2021년 1월 1일 ~ 9월 14일 15분 단위 전력·생산 데이터(24,672행)로 XGBoost 기반 전력사용량 예측 모델을 개발하였다.
- 초기 모델(Feature4)은 15분 앞 예측에서 Test $R^2 = 0.983$을 보였으나, 직전 값을 그대로 쓰는 Persistence($R^2 = 0.953$) 대비 개선은 $+0.03$이었고, 시간 단위 생산실적의 선(先)사용, 피크 과소예측, 평일 휴무 미반영이라는 한계를 확인하였다.
- 개선 모델은 예측 구간(15분·1시간·24시간)과 정보 가용성(실적기반·계획기반)을 분리하여 평가하였다. **24시간 앞 예측에서 Persistence $R^2 = 0.10$ 대비 실적기반 0.85, 계획기반 0.90**을 달성하였다.
- 검증 구간에서 경보 임계값을 선택하여 15분 앞 고전력 경보의 Recall을 0.60에서 0.82로 높였다.
- 월별 최대피크 9건은 모두 **08:30~11:30, 생산지속 상태**에서 발생했으며, 피크 직전 1시간 동안 평균 전력이 134에서 212로 급상승하였다. 이를 근거로 아침 설비 순차 가동과 오전 고부하 생산의 시간대 이동을 저감방안으로 제안한다.

차 례

1 과제 개요 **3**

2 데이터 **3**

2.1 데이터 구성 3

2.2 탐색적 분석 4

2.3 데이터 품질 점검 4

3 초기 모델 (Feature4 XGBoost) **5**

3.1 설계 5

3.2 결과 5

4 초기 모델의 한계 진단 **6**

4.1 한계 1: 개선의 대부분은 lag 정보 자체에서 나온다 6
4.2 한계 2: 시간 내 미래 정보 사용 6
4.3 한계 3: 피크 과소예측 7
4.4 한계 4: 평일 휴무 미반영 7

5 개선 모델 설계 **8**
5.1 예측 구간 분리 8
5.2 정보 가용성에 따른 두 시나리오 8
5.3 휴무 반영과 데이터 보정 8
5.4 피크 대응 8

6 개선 결과 **8**
6.1 회귀 성능 9
6.2 개선 요소별 기여 (24시간 앞, 계획기반) 9
6.3 고전력 경보 성능 10

7 예측오차 및 최대피크 발생 조건 분석 **11**
7.1 예측오차가 큰 생산조건 11
7.2 최대전력 피크 발생 조건 12

8 피크전력 저감방안 **12**

9 한계 및 향후 과제 **13**

A 재현 방법 **13**

1 과제 개요

제조기업의 전력사용량은 설비 동시 가동, 생산량 변화, 제품 전환, 교대시간 및 계절 요인에 따라 크게 변한다. 최대수요전력이 예상보다 높아지면 전력비용이 증가하고, 특정 시간대에 부하가 집중되면 생산 운영의 안정성도 낮아진다. 과제는 다음 세 가지를 요구한다.

1) 향후 지정된 시간구간의 전력사용량을 예측하는 AI 모델 개발

2) 예측오차가 크게 발생하는 생산조건과 최대전력 피크 발생 조건 분석

3) 생산일정 또는 설비가동 시점 조정을 통한 피크전력 저감방안 제안

본 보고서는 초기 모델(제2–4장)을 설계하고 그 한계를 진단한 뒤, 이를 보완한 개선 모델(제5–6장)을 제시한다. 이어 오차·피크 조건을 분석하고(제7장) 저감방안을 제안한다(제8장).

2 데이터

2.1 데이터 구성

주 데이터 `Power15MinClean_NoDatetime.csv`는 2021-01-01 00:15부터 2021-09-15 00:00까지 15분 간격 24,672행(257일 × 96칸, 결측 시점 없음), 17개 열로 구성된다.

변수	설명
날짜, 시간, 분	시각 정보. 분은 15/30/45/60으로 기록되며 60은 다음 정각을 의미한다.
전력사용량	**예측 대상**. 범위 0∼222, 평균 93.3
평균	해당 시간 4개 전력값의 평균(100% 일치) → 정답 누수 변수로 **제외**
생산량	시간 단위 생산 실적. 1시간 동안 같은 값이 4번 반복된다.
공장인원, 인건비	인원 지표(결측 68개), 인건비 계수(1.0 / 1.5)
기온, 풍속, 습도, 강수량	시간 단위 기상 관측값
전기요금(계절), day, d, m	계절 요금(3단계), 요일(1=월 ∼ 7=일), 일, 월
이상구간여부	사후 생성 가능성이 있어 입력에서 **제외** (비율 0.28%)

표 1: 주요 변수

2.2 탐색적 분석

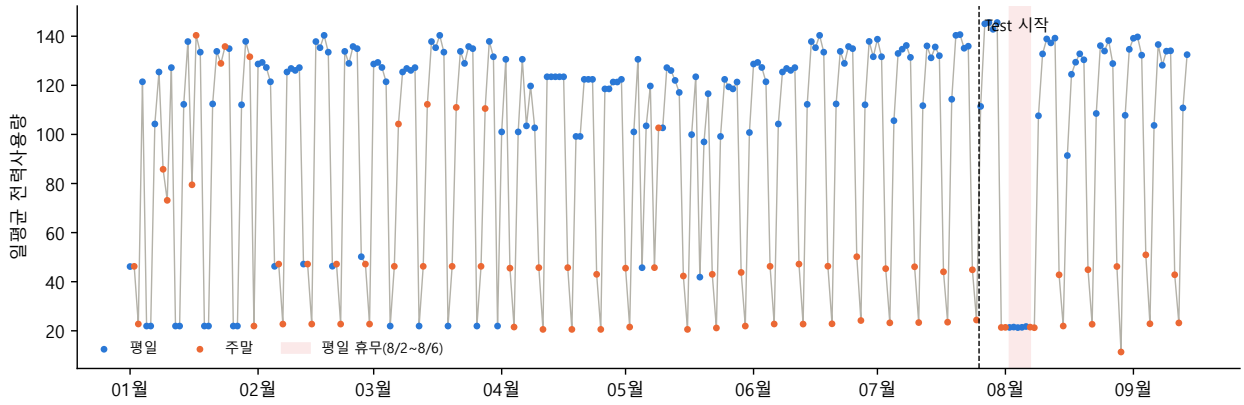


그림 1: 일평균 전력사용량. 평일과 주말의 차이가 크며, 8월 2일~6일은 평일임에도 주말 수준으로 떨어진다.

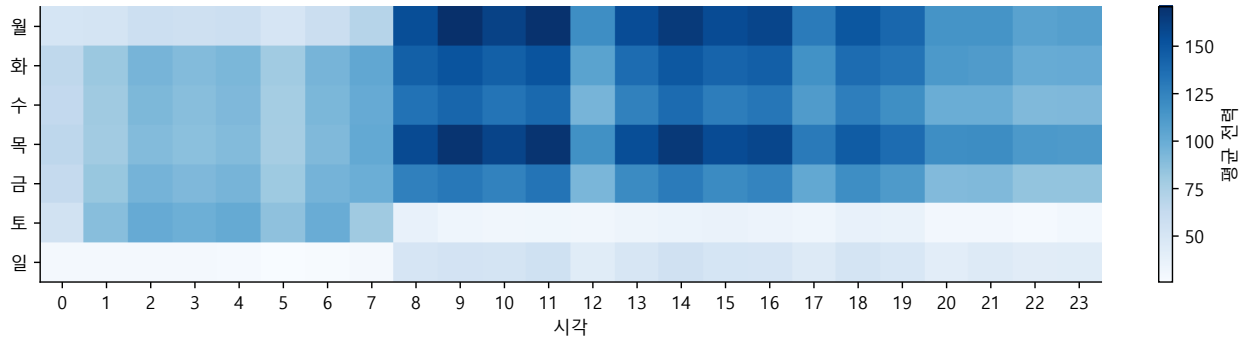


그림 2: 요일 × 시각별 평균 전력. 평일 오전 8~11시와 오후 13~16시에 부하가 집중되고, 12시(점심)에 일시적으로 감소한다.

- 주말(토·일) 평균 전력은 41~51로 평일(103~123)의 절반 이하이다.
- 15분 전 전력과의 자기상관은 0.97로 매우 높아, 직전 값만으로도 상당한 예측력이 있다.
- 전력과의 상관이 가장 큰 변수는 생산량(0.51), 요일(-0.43), 공장인원(0.29) 순이다.

2.3 데이터 품질 점검

발견된 데이터 문제

- **생산 기록 누락:** 7월 13일과 15일은 생산량·공장인원이 하루 종일 0인데 일평균 전력은 약 136으로 평소 가동일 수준이다. 보조 파일 `okm_augumented_2021.csv`에서도 같은 두 날짜의 시간 값이 70~188로 깨져 있어 기록 오류로 판단하였다. 개선 모델에서는 해당일 생산량·공장인원을 결측으로 처리하였다.
- **생산량 0 ≠ 휴무:** 공휴일(2/11, 3/1)과 일부 일요일도 생산량은 0이지만 전력은 100 이상이다. 따라서 생산량만으로 휴무 여부를 판단할 수 없다.
- **평일 휴무:** 8월 2일~6일(월~금)은 전력이 약 21로 주말 수준이다. 여름휴가로 추정되며 Test 구간에 포함되어 있다.

3 초기 모델 (Feature4 XGBoost)

3.1 설계

- **Baseline:** 누수 변수(평균, 이상구간여부)를 제외한 13개 변수로 학습한 XGBoost.
- **Feature4:** Baseline 변수에 4개 파생변수를 추가하였다.
  - `lag_1_power`: 15분 전 전력, `lag_4_power`: 1시간 전 전력
  - `production_change`: 직전 대비 생산량 변화
  - `operation_state`: 생산 전환 상태(비생산지속 / 생산시작 / 생산종료전환 / 생산지속)
- **하이퍼파라미터:** `n_estimators=500`, `learning_rate=0.03`, `max_depth=6`, `subsample=0.8`, `colsample_bytree=0.8`.
- **검증:** 시간순 8:2 분할(Test: 2021-07-25 ∼ 09-14, 4,934행). TimeSeriesSplit 5-fold로 안정성을 확인하였다.
- **비교 기준:** Persistence, 즉 $\hat{P}_t = P_{t-1}$ (직전 값 그대로 사용).

3.2 결과

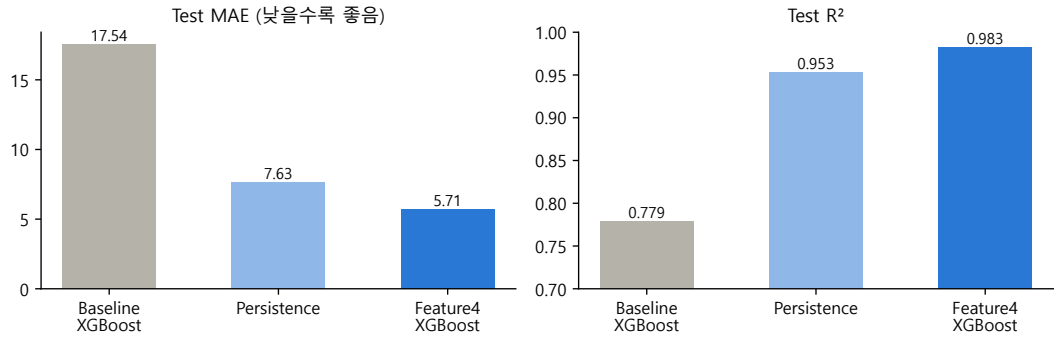


그림 3: 초기 모델 Test 성능 (원본 노트북 실행 결과)

모델	MAE	RMSE	R^2	Train−Test R^2 차이
Baseline XGBoost	17.54	29.17	0.779	0.189
Persistence	7.63	13.50	0.953	–
Feature4 XGBoost	**5.71**	**8.20**	**0.983**	0.006

표 2: 초기 모델 성능 비교

TimeSeriesSplit 5-fold 평균은 Feature4 $R^2 = 0.973$(표준편차 0.009), Persistence $R^2 = 0.941$로, 단일 분할 결과와 같은 경향을 보였다.

4 초기 모델의 한계 진단

4.1 한계 1: 개선의 대부분은 lag 정보 자체에서 나온다

Baseline에서 Feature4로 MAE가 17.5에서 5.7로 줄었지만, 학습 없이 직전 값을 베끼는 Persistence가 이미 7.6을 달성한다. 개선분 11.8 중 9.9는 "15분 전 전력"이라는 정보 자체의 기여이고, 모델이 추가로 기여한 몫은 1.9이다. SHAP 분석에서도 `lag_1_power`의 평균 |SHAP|이 45.1로, 2위 `lag_4_power`(3.8)의 10배 이상이다.

이 정보는 15분 앞 예측에서만 쓸 수 있다. 그림 4처럼 예측 구간이 길어지면 과거 값의 설명력은 급격히 떨어진다. 생산일정 조정에 필요한 몇 시간~하루 앞 예측에서는 초기 모델 구조를 그대로 쓸 수 없다.

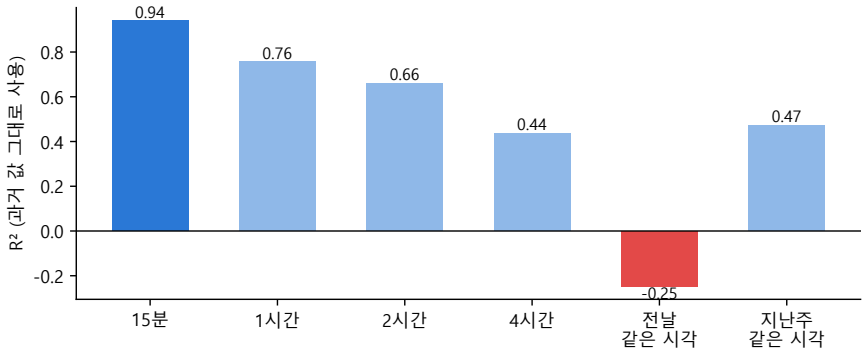


그림 4: 예측 구간별 "과거 값 그대로 쓰기"의 R^2 (전체 데이터). 전날 같은 시각 값은 주말·평일 전환 때문에 음수가 된다.

4.2 한계 2: 시간 내 미래 정보 사용

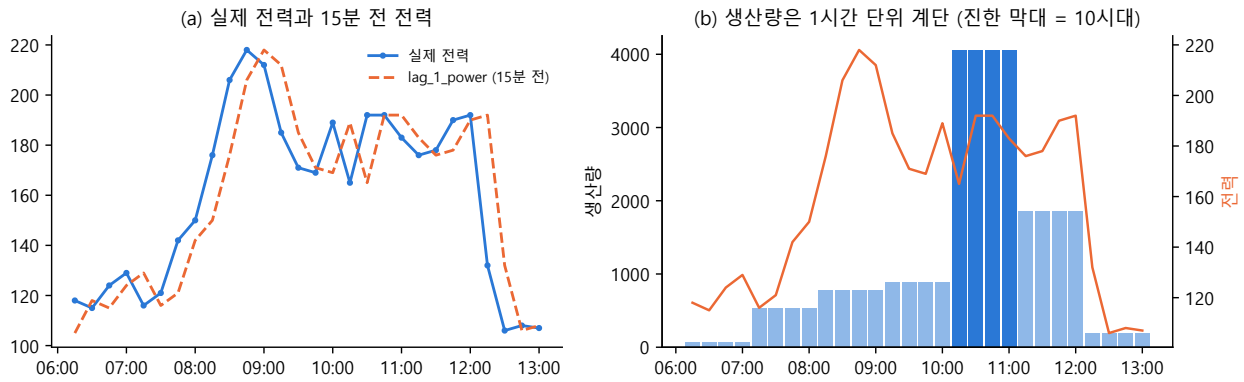


그림 5: 2021-08-11 오전. (a) `lag_1_power`는 실제 전력을 한 칸 늦게 따라간다. (b) 생산량은 1시간 단위 실적이라 10:15 행에 이미 10시대 전체 생산량(4,050)이 들어 있다.

생산량은 1시간이 끝나야 확정되는 실적인데, 모델은 해당 시간의 첫 15분 행부터 이 값을 입력으로 받는다. 따라서 `production_change`는 매시 15분 행에서만 0이 아니다. 기온 등 기상 변수도 같은 시각의 실제 관측값이다. 즉 초기 모델은 "그 시각의 생산 실적과 날씨를 안다면"이라는 조건부 예측이다.

4.3 한계 3: 피크 과소예측

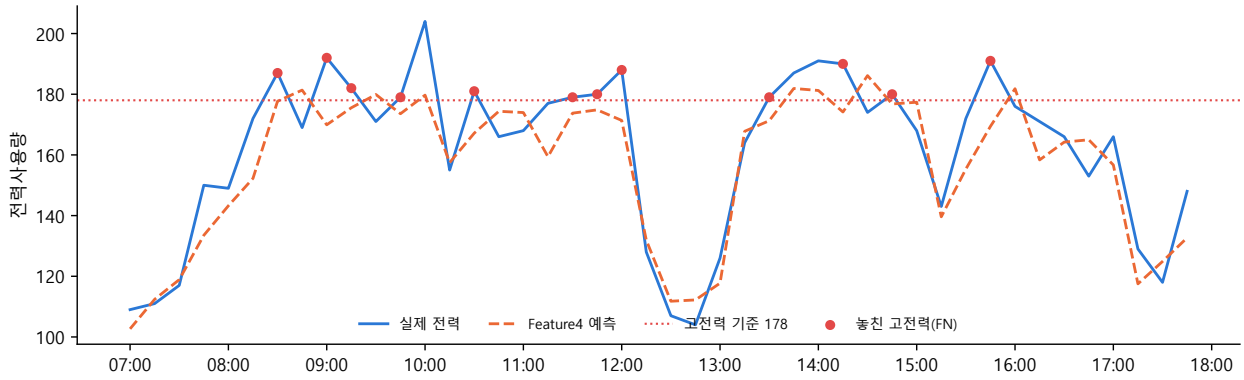


그림 6: 2021-09-10 실제 전력과 Feature4 예측. 봉우리마다 예측이 실제보다 낮다.

실제 전력 구간	건수	실제 평균	예측 평균	차이
100 ∼ 150	1,360	118.0	117.8	−0.2
150 ∼ 178	690	165.1	165.7	+0.6
178 ∼ 200	416	186.3	179.2	**−7.1**
200 이상	65	204.7	192.0	**−12.7**

표 3: 실제 전력 구간별 평균 예측값 (Test)

실제 고전력(178 이상) 시점의 85%에서 예측이 실제보다 낮았다. 제곱오차 목적함수는 불확실한 조건에서 예측을 평균 쪽으로 끌어당기기 때문에, 드문 피크일수록 낮게 예측된다. 그 결과 고전력 경보의 Recall은 0.62에 그쳐 실제 고전력 481건 중 182건을 놓쳤다.

4.4 한계 4: 평일 휴무 미반영

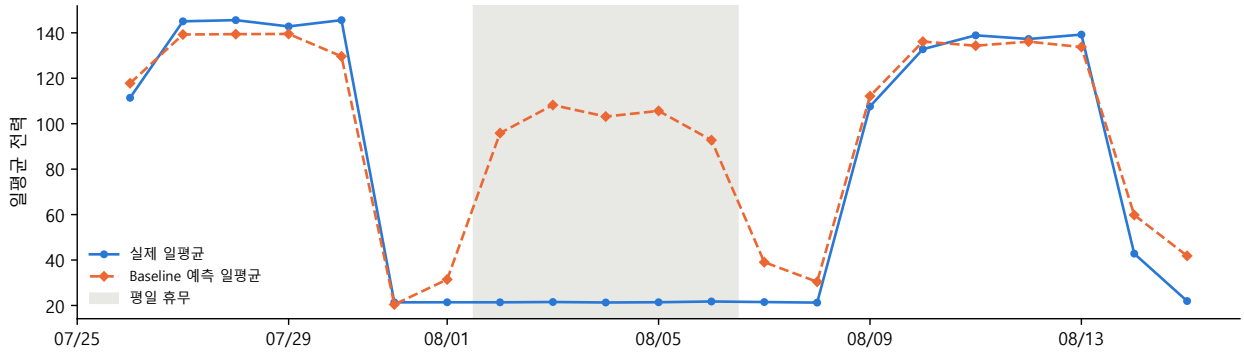


그림 7: Test 구간 일평균 전력과 Baseline 예측. 8/2∼8/6 평일 휴무를 평소 평일로 예측하였다.

휴무 주간에도 생산량·공장인원은 0으로 기록되어 있었다. 그러나 이 값은 평일 야간이나 점심시간에도 흔히 나타나므로, 모델은 이를 "평일 중 잠시 생산이 없는 시간"으로 해석하였다. Baseline 대규모 오차 상위 5%의 대부분이 이 주간에서 발생했다. 시간 단위 변수만으로는 "하루 전체가 휴무"라는 정보를 표현할 수 없다.

5 개선 모델 설계

5.1 예측 구간 분리

15분($h = 1$), 1시간($h = 4$), 24시간($h = 96$) 앞 예측 모델을 각각 학습하였다. 모든 전력 lag는 예측 구간 이상 떨어진 값만 사용하여, 예측 시점 $t - h$에 실제로 알 수 있는 정보만 입력된다.

lag $\in \{h,\ h+1,\ h+4,\ 96^{(h<96)},\ 672\}$, 최근 1시간·24시간 평균 $= \overline{P}_{[t-h-3,\,t-h]},\ \overline{P}_{[t-h-95,\,t-h]}$

5.2 정보 가용성에 따른 두 시나리오

	실적기반	계획기반
가정	예측 시점에 이미 끝난 정보만 사용	생산계획·기상예보를 미리 안다고 가정
생산량	예측 시점까지 완료된 시간의 실적	대상 시각의 생산량(=계획)
공장인원	완료된 시간의 실적	대상 시각의 값(=계획)
기상	예측 시점의 관측값	대상 시각의 값(=예보)
의미	누수 없음. 지금 바로 운영 가능한 성능	생산계획 정보의 가치

표 4: 시나리오 정의. 두 시나리오 모두 달력 변수와 전력 lag를 공통으로 사용한다.

5.3 휴무 반영과 데이터 보정

- **가동일 달력:** 일평균 전력이 30 미만인 날을 휴무일로 표시하였다(257일 중 49일, 평일 휴무 18일).
- **생산 기록 누락일 보정:** 7/13, 7/15의 생산량·공장인원을 결측 처리하였다.

가정 명시

가동일 달력은 실제 전력으로 만든 대리 변수이다. 공장이 휴무 계획(여름휴가, 공휴일 등)을 사전에 알고 있다는 가정에 근거하며, 실제 적용 시에는 회사의 휴무 달력으로 대체해야 한다.

5.4 피크 대응

- **학습 가중치:** 고전력(Train 95% 분위수 178 이상) 데이터에 가중치 3을 부여하였다.
- **경보 임계값 선택:** Train의 뒤쪽 20%(2021-06-16 ~ 07-25)를 검증 구간으로 두고, 검증 F1이 최대가 되는 예측 임계값을 선택하였다. Test는 임계값 선택에 사용하지 않았다.

6 개선 결과

Train은 lag 생성을 위해 앞쪽 800행을 제외한 18,938행이며, Test는 초기 모델과 동일한 4,934행이다. 비교를 위해 초기 Feature4도 같은 Train 행으로 다시 학습하였다.

6.1 회귀 성능

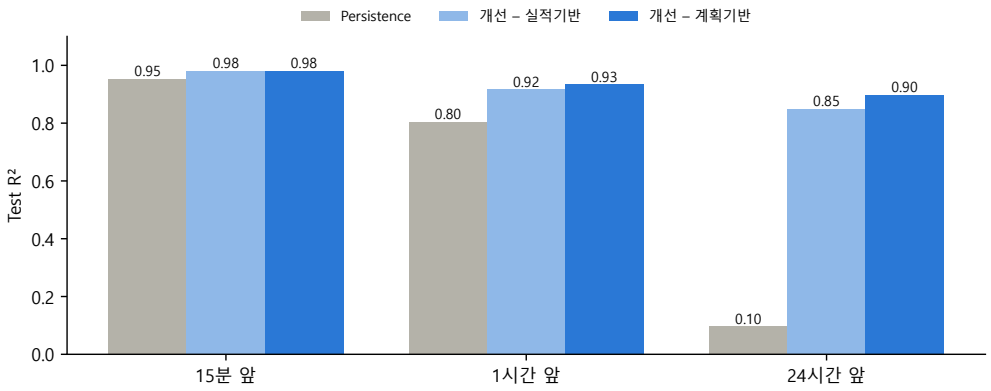


그림 8: 예측 구간별 Test R^2. 예측 구간이 길수록 Persistence 대비 개선 폭이 커진다.

예측 구간	모델	MAE	R^2	Pers. MAE	Pers. R^2	MAE 개선
15분 앞	초기 Feature4 (재학습)	6.23	0.980	7.63	0.953	1.39
	개선 – 실적기반	5.60	0.981	7.63	0.953	2.02
	개선 – 계획기반	**5.50**	**0.981**	7.63	0.953	2.13
1시간 앞	개선 – 실적기반	11.51	0.916	16.16	0.804	4.65
	개선 – 계획기반	**10.03**	**0.934**	16.16	0.804	6.13
24시간 앞	개선 – 실적기반	15.29	0.849	33.85	0.096	18.56
	개선 – 계획기반	**12.51**	**0.898**	33.85	0.096	21.34

표 5: 개선 모델 회귀 성능 (Test)

- 15분 앞에서는 실적기반과 계획기반의 차이가 작다(MAE 5.60 vs 5.50). 초기 모델의 시간 내 미래 정보 사용은 단기 예측 성능을 크게 부풀리지 않았다.
- 24시간 앞에서는 생산계획을 알면 MAE가 15.3에서 12.5로 줄어든다. 생산계획 정보의 가치를 보여준다.

6.2 개선 요소별 기여 (24시간 앞, 계획기반)

구성	MAE	R^2	경보 F1 (검증선택)
전체 (가동일 달력 + 고전력 가중치)	12.51	0.898	0.576
가동일 달력 제외	20.06	0.728	0.569
고전력 가중치 제외	12.54	0.900	0.576

표 6: Ablation. 가동일 달력의 효과가 가장 크고, 고전력 가중치의 효과는 미미하다.

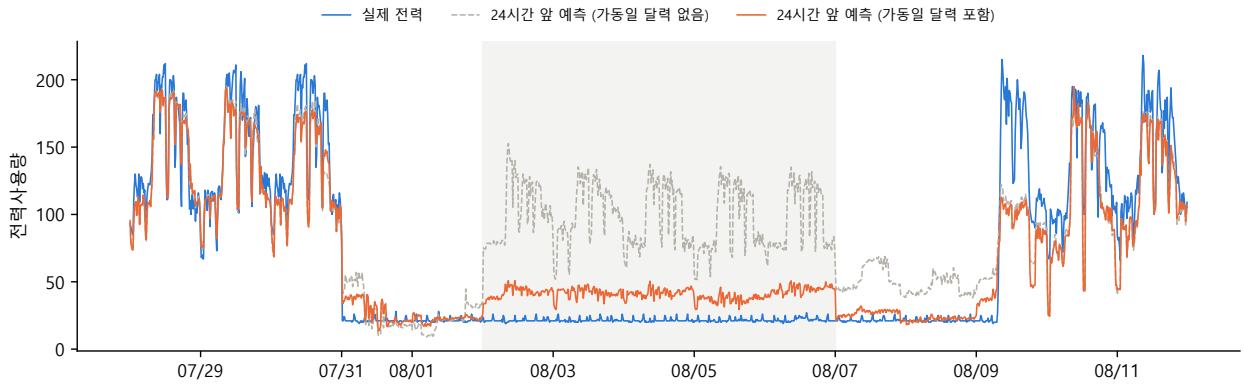


그림 9: 24시간 앞 예측의 휴무 주간 전후. 가동일 달력이 없으면 휴무 주간을 평일 수준으로 예측한다.

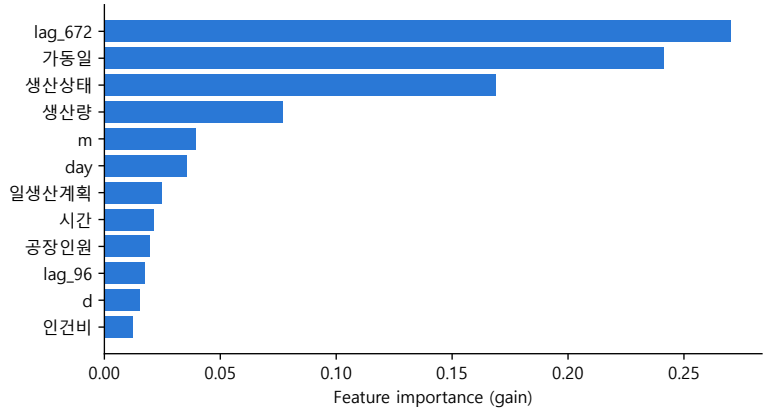


그림 10: 24시간 앞(계획기반) 모델 변수 중요도 상위 12. 1주 전 같은 시각 전력, 가동일, 생산상태, 생산량 순이다.

6.3 고전력 경보 성능

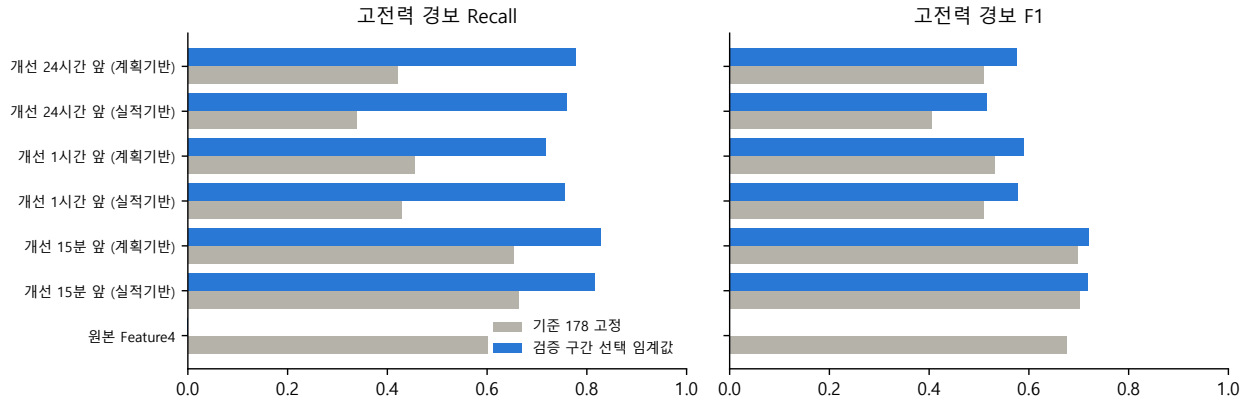


그림 11: 고전력 경보 Recall과 F1. 정답은 실제 전력 ≥ 178이다.

모델	기준 178 고정			검증 선택 임계값			
	Precision	Recall	F1	임계값	Precision	Recall	F1
초기 Feature4 (재학습)	0.773	0.601	0.676	–	–	–	–
15분 앞 실적기반	0.745	0.663	0.702	173	0.642	0.815	0.718
15분 앞 계획기반	0.749	0.653	0.698	172	0.637	0.827	**0.720**
1시간 앞 실적기반	0.628	0.428	0.509	165	0.467	0.755	0.577
1시간 앞 계획기반	0.638	0.455	0.532	169	0.501	0.717	0.590
24시간 앞 실적기반	0.503	0.339	0.405	154	0.390	0.759	0.515
24시간 앞 계획기반	0.645	0.420	0.509	164	0.457	0.778	0.576

표 7: 고전력 경보 성능 (Test)

임계값을 낮추면 Recall은 크게 오르고 Precision은 내려간다. 피크를 놓치는 비용(최대수요전력 상승에 따른 기본요금 증가)이 불필요한 경보의 비용보다 크다는 판단에 따라 Recall 쪽을 선택하였다. 실제 운영에서는 두 오류의 비용을 정한 뒤 임계값을 다시 선택해야 한다.

7 예측오차 및 최대피크 발생 조건 분석

본 장의 수치는 초기 Feature4 모델의 Test 구간 결과이다.

7.1 예측오차가 큰 생산조건

절대오차 상위 5%(17.2 이상, 247건)를 대규모 오차로 정의하였다.

구분	조건	건수	평균 절대오차	대규모 오차율
생산량 구간	생산량 = 0	2,062	3.44	2.8%
	생산량 1,238 초과	716	8.56	**9.8%**
생산량 변화	증가	404	8.30	**9.2%**
	감소	346	7.82	7.5%
	변화 없음	4,184	5.28	4.4%
생산 상태	생산시작	34	8.57	8.8%
	생산지속	2,838	7.31	6.6%
	비생산지속	2,029	3.38	2.8%
공장인원	인원 $>$ 0	2,940	7.56	**7.6%**
	인원 = 0	1,994	2.97	1.2%

표 8: 조건별 대규모 오차율 (전체 평균 5%)

- 오차는 **생산 중, 특히 고생산량 구간과 생산량이 바뀌는 시점**에 집중된다. 비생산 구간의 오차는 작다.
- 대규모 오차 247건 중 과소예측은 121건(실제 평균 165.9, 예측 143.5), 과대예측은 126건(실제 83.3, 예측 105.3)이다. 고부하는 낮게, 부하 감소는 늦게 따라가는 경향이 있다.
- 고전력 경보의 FN율(실제 고전력 중 놓친 비율)은 18시 81%, 16시 61%, 15시 53%로 **오후 부하 감소 직전**에 높았다. FP율은 9시(12.6%), 14시(11.1%), 11시(10.8%)에 높았다.

7.2 최대전력 피크 발생 조건

월별 최대피크는 각 월의 15분 관측값 중 최댓값으로 정의하였다(9건, 동률 없음). 표본이 적으므로 각 월 상위 5%(1,298건)를 고전력 위험구간으로 정의하여 보조 분석하였다.

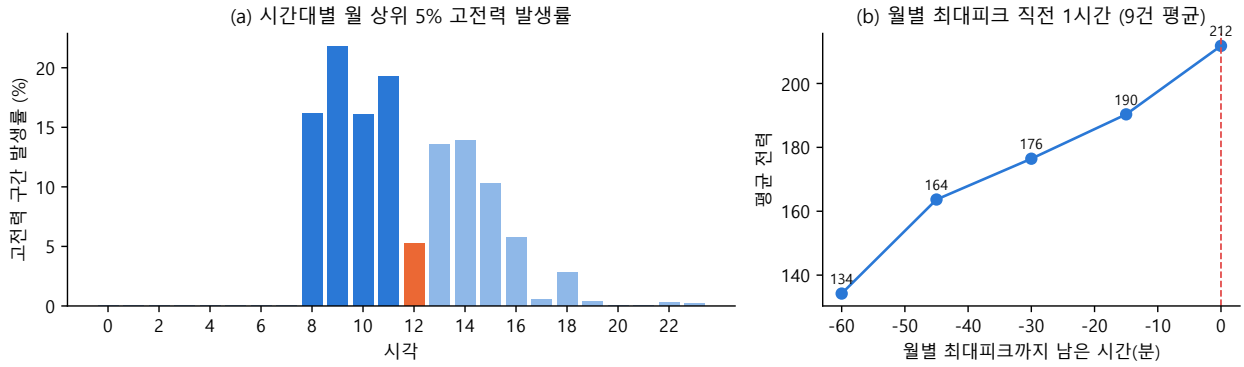


그림 12: (a) 시간대별 고전력 위험구간 발생률. 8~11시에 집중되고 12시에 급감하며, 17시 이후에는 3% 미만이다. (b) 월별 최대피크 직전 1시간의 평균 전력.

조건	월별 최대피크 (9건)	고전력 위험구간 (월 상위 5%)
시간대	9건 모두 08:30~11:30	9시 발생률 21.8% (전체 대비 4.1배)
생산 상태	9건 모두 생산지속	생산지속이 90.1% 차지 (1.6배)
생산량	중앙값 783 (전체 중앙값 45)	498~1,175 구간이 41.9% 차지 (3.0배)
생산량 변화	9건 모두 변화 없음	변화 없음 87.6% (1.03배)
공장인원	9건 모두 인원 > 0	인원 > 0이 90.4% 차지 (1.6배)

표 9: 피크 발생 조건. 괄호는 전체 데이터 비율 대비 집중도이다.

피크 발생 메커니즘 해석

최대피크는 생산량이 급변하는 순간이 아니라, **아침 가동 후 중간 이상 생산량으로 생산이 지속되는 오전 시간대**에 발생한다. 피크 직전 1시간 평균 전력은 134 → 164 → 176 → 190 → 212로 15분마다 계단식으로 상승한다. 오전에 설비가 순차적으로 추가 가동되며 부하가 누적되는 패턴으로 해석된다. 단, 설비별 데이터가 없어 이 해석은 연관성에 근거하며 인과관계를 입증하지 않는다.

8 피크전력 저감방안

제7장의 분석을 근거로 다음 방안을 제안한다.

방안 1. 아침 설비 가동 순차화. 피크 직전 1시간 동안 전력이 78 상승한다. 8~9시에 설비를 동시에 가동하지 말고 15~30분 간격으로 순차 가동하여 상승 기울기를 완만하게 만든다.

방안 2. 오전 고부하 생산의 시간대 이동. 고전력 발생률은 9시 21.8%, 11시 19.3%인 반면 12시는 5.3%, 17시 이후는 3% 미만이다. 생산량 498~1,175 구간의 오전 작업 일부를 점심 직후나 17시 이후로 옮긴다. 야간으로 옮길 경우 인건비 계수(1.5)를 함께 고려해야 한다.

방안 3. 예측 기반 2단계 운영.

- 전날: 24시간 앞 계획기반 모델로 다음 날 시간대별 전력을 예측하고, 고전력이 예상되는 시간대의 생산계획을 조정한다.
- 당일: 15분 앞 모델의 경보(검증 선택 임계값, Recall 0.82)로 피크 직전에 비필수 부하를 일시 차단한다.

방안 4. 오후 부하 감소 구간의 경보 보완. 15~18시는 FN율이 높으므로 이 시간대에는 경보 임계값을 별도로 낮게 설정하는 것을 검토한다.

정량 효과 검증은 향후 과제

위 방안의 피크 저감량과 비용 절감액은 아직 정량화하지 않았다. 24시간 앞 계획기반 모델은 생산계획을 입력으로 받으므로, 생산량을 다른 시간대로 옮긴 시나리오를 입력해 월별 최대전력 변화를 시뮬레이션할 수 있다. 줄어든 최대전력에 기본요금 단가를 곱해 절감액도 추정할 수 있다.

9 한계 및 향후 과제

- **가동일 달력 가정:** 실제 전력으로 만든 대리 변수이므로, 회사의 휴무 달력으로 대체한 뒤 재평가해야 한다. 이 변수가 없으면 24시간 앞 R^2는 0.73이다.
- **Test 독립성:** 개선 방향을 정하는 과정에서 Test 결과를 참고한 실험이 있었다. 최종 설계는 고정 규칙을 사용했으나, 완전히 독립된 평가를 위해 별도 기간(예: 2021년 10월 이후) 데이터로 재검증이 필요하다.
- **계획 정보:** 계획기반 시나리오는 실적을 계획으로 간주한 것이다. 실제 생산계획과 실적의 차이가 있으면 성능이 낮아질 수 있다.
- **데이터 기간:** 1~9월 데이터로 겨울철 난방 부하나 연말 패턴은 학습되지 않았다.
- **설비 단위 정보 부재:** 설비별 전력이나 가동 기록이 있으면 동시 가동의 영향을 직접 분석할 수 있다.

A 재현 방법

파일	내용
`KAMP_modeling_3_7.py`	초기 모델 전체 분석 (Baseline, Feature4, 오차·피크·경보·SHAP 분석)
`KAMP_modeling_improved.py`	개선 모델 (예측 구간 × 시나리오, Ablation, 그림)
`report/make_figures.py`	보고서 그림 생성
`outputs/`	예측 결과 및 분석표 CSV

실행 환경: Python 3, pandas 3.0, scikit-learn 1.9, xgboost 3.4.
각 스크립트를 데이터 파일 `Power15MinClean_NoDatetime.csv`와 같은 폴더에 두고 Spyder에서 실행한다.

초기 모델 수치는 원본 노트북(Colab) 결과이며, 패키지 버전에 따라 소수점 셋째 자리에서 차이가 날 수 있다.